

HDBSCAN con Pesos: Ejemplo Numérico Completo

Extensión del Clustering Basado en Densidad con Sample Weights

Adaptación del método de Campello, Moulavi & Sander (PAKDD 2013)

Abstract

Este documento presenta la extensión de HDBSCAN para incorporar **pesos de muestra** (sample weights). Se desarrolla un ejemplo numérico completo mostrando cómo los pesos afectan exclusivamente la fase de condensación del árbol y el cálculo de estabilidades, sin modificar la geometría del espacio (distancias, core distances, mutual reachability). Se incluye fundamentación teórica de la extensión.

Contents

1	Introducción: HDBSCAN Estándar vs. Ponderado	2
1.1	Diferencia Fundamental	2
1.2	Notación Extendida	2
1.3	Parámetros	2
2	Dataset de Ejemplo con Pesos	2
2.1	Descripción del Conjunto de Datos	2
2.2	Visualización con Pesos	3
3	Pasos 1-5: Sin Cambios por Pesos	3
3.1	Core Distances (Paso 2)	3
3.2	Mutual Reachability Distances (Paso 3)	3
3.3	MST (Pasos 4-5)	4
4	Paso 6: Construcción del Dendrograma con Pesos	4
4.1	Criterio de Cluster Válido Modificado	4
4.2	Nivel $\varepsilon = 6.50$: Remover arista 6–9	4
4.3	Nivel $\varepsilon = 1.60$: Remover arista 11–13	4
4.4	Nivel $\varepsilon = 0.90$: Remover arista 2–5	4
4.5	Nivel $\varepsilon = 0.566$: Desaparición de Cluster_B	4
4.6	Nivel $\varepsilon = 0.424$: Desaparición de A1 y A2	4
5	Paso 7: Árbol de Clusters Simplificado (Con Pesos)	5
6	Paso 8: Cálculo de Estabilidades con Pesos	5
6.1	Fórmula de Estabilidad Ponderada	5
6.2	Estabilidad de Cluster_A1	5
6.3	Estabilidad de Cluster_A2	5
6.4	Estabilidad de Cluster_A	6
6.5	Estabilidad de Cluster_B	6
6.6	Estabilidad de Cluster_BC	6
6.7	Tabla Resumen de Estabilidades	7

7	Paso 9: Extracción Óptima con Pesos	7
7.1	Árbol con Estabilidades Ponderadas	7
7.2	Algoritmo de Selección Bottom-Up	7
7.3	Decisiones de Selección	7
7.4	Estabilidad Total Óptima	7
8	Resultado Final	8
8.1	Partición Óptima con Pesos	8
8.2	Comparación: Sin Pesos vs. Con Pesos	8
8.3	Visualización del Resultado	8
9	Fundamentación Teórica de la Extensión con Pesos	9
9.1	Axioma de Pesos	9
9.2	Justificación: No Modificar la Geometría	9
9.3	Justificación: Modificar Solo la Condensación	9
9.4	Propiedad de Consistencia	9
9.5	Interpretación Práctica	9
10	Resumen del Algoritmo HDBSCAN con Pesos	10
11	Conclusiones	10

1 Introducción: HDBSCAN Estándar vs. Ponderado

1.1 Diferencia Fundamental

En HDBSCAN estándar, cada punto tiene peso implícito $w_i = 1$. La extensión con pesos permite $w_i \in \mathbb{R}^+$ arbitrarios.

Componente	Estándar	Con Pesos
Core distance	$d_{\text{core}}(x_p)$	$d_{\text{core}}(x_p)$ (sin cambio)
Mutual reachability	$d_{\text{mreach}}(x_p, x_q)$	$d_{\text{mreach}}(x_p, x_q)$ (sin cambio)
MST	Igual	Igual
Validez de cluster	$ C \geq m_{\text{clSize}}$	$W(C) \geq m_{\text{clSize}}$
Estabilidad	$\sum_{x_j \in C_i} (\cdot)$	$\sum_{x_j \in C_i} w_j \cdot (\cdot)$

1.2 Notación Extendida

Sea $X = \{x_1, \dots, x_n\}$ con pesos asociados $W = \{w_1, \dots, w_n\}$ donde $w_i > 0$.

Definición 1.1 (Masa de un Conjunto). Para un subconjunto $C \subseteq X$:

$$W(C) = \sum_{x_j \in C} w_j$$

1.3 Parámetros

- m_{pts} : número mínimo de puntos para densidad local (sin cambio)
- m_{clSize} : masa mínima de cluster (ahora comparada contra $W(C)$)

2 Dataset de Ejemplo con Pesos

2.1 Descripción del Conjunto de Datos

Usamos los mismos 16 puntos del ejemplo original, pero con pesos diferenciados:

Table 1: Coordenadas y pesos de los 16 puntos

ID	x	y	Peso w	Grupo	ID	x	y	Peso w	Grupo
1	0.0	0.0	10	A1	9	8.0	0.0	5	B
2	0.3	0.0	10	A1	10	8.4	0.0	5	B
3	0.0	0.3	10	A1	11	8.0	0.4	5	B
4	0.3	0.3	10	A1	12	8.4	0.4	5	B
5	1.2	0.0	5	A2	13	8.0	2.0	2	C
6	1.5	0.0	5	A2	14	8.4	2.0	2	C
7	1.2	0.3	5	A2	15	8.0	2.4	2	C
8	1.5	0.3	5	A2	16	8.4	2.4	2	C


Masas por grupo:

- $W(A1) = 4 \times 10 = 40$
- $W(A2) = 4 \times 5 = 20$
- $W(B) = 4 \times 5 = 20$

- $W(C) = 4 \times 2 = 8$

Parámetros: $m_{\text{pts}} = 4$, $m_{\text{clSize}} = 15$ (masa mínima)

2.2 Visualización con Pesos



Nota: El tamaño de los círculos representa el peso relativo.

3 Pasos 1-5: Sin Cambios por Pesos

Los pesos **no** afectan los pasos geométricos del algoritmo:

3.1 Core Distances (Paso 2)

Definición 3.1 (Core Distance — Sin Cambio).

$$d_{\text{core}}(x_p) = d(x_p, x_p^{(m_{\text{pts}})})$$

donde $x_p^{(m_{\text{pts}})}$ es el m_{pts} -ésimo vecino más cercano.

Los pesos **no** modifican qué puntos son vecinos ni sus distancias.

Table 2: Core distances (idénticas al caso sin pesos)

Punto	1–4	5–8	9–12	13–16
d_{core}	0.424	0.424	0.566	0.566

3.2 Mutual Reachability Distances (Paso 3)

Definición 3.2 (Mutual Reachability Distance — Sin Cambio).

$$d_{\text{mreach}}(x_p, x_q) = \max\{d_{\text{core}}(x_p), d_{\text{core}}(x_q), d(x_p, x_q)\}$$

Valores clave:

- Dentro de A1, A2: $d_{\text{mreach}} = 0.424$
- Dentro de B, C: $d_{\text{mreach}} = 0.566$
- $A1 \leftrightarrow A2$: $d_{\text{mreach}}(2, 5) = 0.90$
- $B \leftrightarrow C$: $d_{\text{mreach}}(11, 13) = 1.60$
- $A \leftrightarrow BC$: $d_{\text{mreach}}(6, 9) = 6.50$

3.3 MST (Pasos 4-5)

El MST es **idéntico** al caso sin pesos. La estructura del árbol no cambia.

4 Paso 6: Construcción del Dendrograma con Pesos

Aquí comienzan las diferencias. Al remover aristas, verificamos si los componentes tienen **masa suficiente**.

4.1 Criterio de Cluster Válido Modificado

Definición 4.1 (Cluster Válido con Pesos). Un componente C es un cluster válido si y solo si:

$$W(C) = \sum_{x_j \in C} w_j \geq m_{\text{clSize}}$$

Con $m_{\text{clSize}} = 15$:

4.2 Nivel $\varepsilon = 6.50$: Remover arista 6–9

Se forman dos componentes:

- $\{1, \dots, 8\}$: $W = 40 + 20 = 60 \geq 15 \checkmark \Rightarrow$ **Cluster_A** válido
- $\{9, \dots, 16\}$: $W = 20 + 8 = 28 \geq 15 \checkmark \Rightarrow$ **Cluster_BC** válido

4.3 Nivel $\varepsilon = 1.60$: Remover arista 11–13

Cluster_BC se divide:

- $\{9, 10, 11, 12\}$: $W = 20 \geq 15 \checkmark \Rightarrow$ **Cluster_B** válido
- $\{13, 14, 15, 16\}$: $W = 8 < 15 \Rightarrow$ **Spurious (ruido)**

Diferencia clave: En el caso sin pesos, Cluster_C era válido ($4 \text{ puntos} \geq 4$). Con pesos, su masa es insuficiente.

Los puntos 13–16 se marcan como ruido con $\varepsilon_{\min} = 1.60$.

4.4 Nivel $\varepsilon = 0.90$: Remover arista 2–5

Cluster_A se divide:

- $\{1, 2, 3, 4\}$: $W = 40 \geq 15 \checkmark \Rightarrow$ **Cluster_A1** válido
- $\{5, 6, 7, 8\}$: $W = 20 \geq 15 \checkmark \Rightarrow$ **Cluster_A2** válido

4.5 Nivel $\varepsilon = 0.566$: Desaparición de Cluster_B

Al remover aristas internas de B, cada punto queda aislado con masa $w_j = 5 < 15$.

$\varepsilon_{\min}(p, \text{Cluster_B}) = 0.566$ para $p \in \{9, 10, 11, 12\}$


4.6 Nivel $\varepsilon = 0.424$: Desaparición de A1 y A2

- Cluster_A1: cada punto tiene $w = 10 < 15 \Rightarrow$ desaparece
- Cluster_A2: cada punto tiene $w = 5 < 15 \Rightarrow$ desaparece

$\varepsilon_{\min}(p, \text{Cluster_A1}) = 0.424$ para $p \in \{1, 2, 3, 4\}$

$\varepsilon_{\min}(p, \text{Cluster_A2}) = 0.424$ para $p \in \{5, 6, 7, 8\}$

5 Paso 7: Árbol de Clusters Simplificado (Con Pesos)



Comparación con caso sin pesos:

- Sin pesos: 6 clusters en el árbol (A, A1, A2, BC, B, C)
- Con pesos: 5 clusters válidos + ruido (C no califica)

6 Paso 8: Cálculo de Estabilidades con Pesos

6.1 Fórmula de Estabilidad Ponderada

Definición 6.1 (Estabilidad con Pesos). Para un cluster C_i :

$$S_w(C_i) = \sum_{x_j \in C_i} w_j \cdot \left(\frac{1}{\varepsilon_{\min}(x_j, C_i)} - \frac{1}{\varepsilon_{\max}(C_i)} \right)$$

Equivalentemente, usando $\lambda = 1/\varepsilon$:

$$S_w(C_i) = \sum_{x_j \in C_i} w_j \cdot (\lambda_{\max}(x_j, C_i) - \lambda_{\min}(C_i))$$

6.2 Estabilidad de Cluster_A1

$$\begin{aligned}
 \varepsilon_{\max}(A1) &= 0.90 \\
 \varepsilon_{\min}(p, A1) &= 0.424 \quad \forall p \in \{1, 2, 3, 4\} \\
 S_w(A1) &= \sum_{j=1}^4 w_j \cdot \left(\frac{1}{0.424} - \frac{1}{0.90} \right) \\
 &= (10 + 10 + 10 + 10) \times (2.358 - 1.111) \\
 &= 40 \times 1.247 \\
 &= \boxed{49.88}
 \end{aligned}$$

Comparación: Sin pesos era $S = 4.99$ (10 veces menor).

6.3 Estabilidad de Cluster_A2

$$\begin{aligned}
 S_w(A2) &= (5 + 5 + 5 + 5) \times \left(\frac{1}{0.424} - \frac{1}{0.90} \right) \\
 &= 20 \times 1.247 \\
 &= \boxed{24.94}
 \end{aligned}$$

6.4 Estabilidad de Cluster_A

$$\begin{aligned}
\varepsilon_{\max}(A) &= 6.50 \\
\varepsilon_{\min}(p, A) &= 0.90 \quad \forall p \in \{1, \dots, 8\} \\
S_w(A) &= \sum_{j=1}^8 w_j \cdot \left(\frac{1}{0.90} - \frac{1}{6.50} \right) \\
&= (40 + 20) \times (1.111 - 0.154) \\
&= 60 \times 0.957 \\
&= \boxed{57.42}
\end{aligned}$$

6.5 Estabilidad de Cluster_B

$$\begin{aligned}
\varepsilon_{\max}(B) &= 1.60 \\
\varepsilon_{\min}(p, B) &= 0.566 \quad \forall p \in \{9, 10, 11, 12\} \\
S_w(B) &= (5 + 5 + 5 + 5) \times \left(\frac{1}{0.566} - \frac{1}{1.60} \right) \\
&= 20 \times (1.767 - 0.625) \\
&= 20 \times 1.142 \\
&= \boxed{22.84}
\end{aligned}$$

6.6 Estabilidad de Cluster_BC

Nota: Los puntos de C (13–16) salen como ruido en $\varepsilon = 1.60$, por lo que contribuyen a BC hasta ese nivel.

$$\begin{aligned}
S_w(BC) &= \sum_{j=9}^{16} w_j \cdot \left(\frac{1}{\varepsilon_{\min}(j, BC)} - \frac{1}{6.50} \right) \\
&= \underbrace{20 \times \left(\frac{1}{1.60} - \frac{1}{6.50} \right)}_{\text{puntos de B}} + \underbrace{8 \times \left(\frac{1}{1.60} - \frac{1}{6.50} \right)}_{\text{puntos de C (ruido)}} \\
&= 28 \times (0.625 - 0.154) \\
&= 28 \times 0.471 \\
&= \boxed{13.19}
\end{aligned}$$


Table 3: Comparación de estabildades: sin pesos vs. con pesos

Cluster	S (sin pesos)	S_w (con pesos)	Ratio
Cluster_A	7.66	57.42	$7.5\times$
Cluster_A1	4.99	49.88	$10\times$
Cluster_A2	4.99	24.94	$5\times$
Cluster_BC	3.77	13.19	$3.5\times$
Cluster_B	4.57	22.84	$5\times$
Cluster_C	4.57	—	(ruido)

6.7 Tabla Resumen de Estabilidades

7 Paso 9: Extracción Óptima con Pesos

7.1 Árbol con Estabilidades Ponderadas



7.2 Algoritmo de Selección Bottom-Up

Algorithm 1 Extracción óptima con pesos

- 1: **Inicialización:** $\delta_i = 1$ para hojas
 - 2: $\hat{S}_w(A1) = 49.88$, $\hat{S}_w(A2) = 24.94$, $\hat{S}_w(B) = 22.84$
 - 3:
 - 4: **Procesar Cluster_A:**
 - 5: **if** $S_w(A) < \hat{S}_w(A1) + \hat{S}_w(A2)$ **then**
 - 6: $57.42 < 49.88 + 24.94 = 74.82$ (**Verdadero**)
 - 7: $\hat{S}_w(A) \leftarrow 74.82$, $\delta_A \leftarrow 0$
 - 8: **end if**
 - 9:
 - 10: **Procesar Cluster_BC:**
 - 11: BC solo tiene un hijo válido (B), C es ruido
 - 12: **if** $S_w(BC) < \hat{S}_w(B)$ **then**
 - 13: $13.19 < 22.84$ (**Verdadero**)
 - 14: $\hat{S}_w(BC) \leftarrow 22.84$, $\delta_{BC} \leftarrow 0$
 - 15: **end if**
-

7.3 Decisiones de Selección

7.4 Estabilidad Total Óptima

$$J^* = S_w(A1) + S_w(A2) + S_w(B) = 49.88 + 24.94 + 22.84 = \boxed{97.66}$$

Table 4: Estado final de selección			
Cluster	δ	Comparación	Decisión
Cluster_A	0	$57.42 < 74.82$	Hijos ganan
Cluster_A1	1	(hoja)	Seleccionado
Cluster_A2	1	(hoja)	Seleccionado
Cluster_BC	0	$13.19 < 22.84$	Hijo gana
Cluster_B	1	(hoja)	Seleccionado

8 Resultado Final


8.1 Partición Óptima con Pesos

Table 5: Clustering final con pesos				
Cluster	Puntos	Tamaño	Masa W	Estabilidad S_w
Cluster_A1	1, 2, 3, 4	4	40	49.88
Cluster_A2	5, 6, 7, 8	4	20	24.94
Cluster_B	9, 10, 11, 12	4	20	22.84
Ruido	13, 14, 15, 16	4	8	—
Total	16	16	88	97.66

8.2 Comparación: Sin Pesos vs. Con Pesos

Table 6: Diferencias en el resultado final		
	Sin Pesos	Con Pesos
Número de clusters	4	3
Puntos clasificados como ruido	0	4 (grupo C)
Estabilidad total	19.12	97.66
Cluster C	Válido	Ruido

8.3 Visualización del Resultado



9 Fundamentación Teórica de la Extensión con Pesos

9.1 Axioma de Pesos

Axioma 9.1 (Pesos como Multiplicidad). El peso w_i de un punto x_i representa su “multiplicidad” o importancia relativa. Un punto con peso w es equivalente, para efectos de masa del cluster, a w copias del punto en la misma ubicación.

9.2 Justificación: No Modificar la Geometría

Teorema 9.1 (Separación Geometría-Masa). Los pesos no deben afectar las distancias porque:

1. La core distance estima densidad local basada en vecindad espacial
2. Un punto “pesado” no está físicamente más cerca de otros puntos
3. La mutual reachability distance captura conectividad geométrica

Proof. Si los pesos modificaran las distancias, un punto con peso alto “atraería” artificialmente a sus vecinos, distorsionando la estructura de densidad real del espacio. $\square$

9.3 Justificación: Modificar Solo la Condensación

Teorema 9.2 (Pesos en la Condensación). Los pesos afectan únicamente:

1. El criterio de validez: $W(C) \geq m_{\text{clSize}}$
2. La estabilidad: $S_w(C_i) = \sum_{x_j \in C_i} w_j \cdot (\lambda_{\max,j} - \lambda_{\min})$

Proof. En la condensación, decidimos qué componentes tienen “suficiente masa” para ser clusters. Los pesos representan cuánta masa aporta cada punto, por lo que la suma ponderada es la medida natural. $\square$

9.4 Propiedad de Consistencia

Teorema 9.3 (Caso Especial: Pesos Unitarios). Cuando $w_i = 1$ para todo i :

$$\begin{aligned} W(C) &= |C| \\ S_w(C) &= S(C) \end{aligned}$$

El algoritmo con pesos se reduce exactamente al algoritmo estándar.

9.5 Interpretación Práctica

Observación 9.1 (Uso de Pesos). Los pesos son apropiados cuando:

- Cada punto (x, y) representa múltiples observaciones (conteos)
- Se quiere dar más importancia a ciertas regiones
- Los datos están agregados y el conteo indica frecuencia

Los pesos **no** son apropiados cuando:

- Se quiere que puntos “pesados” atraigan a sus vecinos
- El “peso” es una característica intrínseca que define similitud

En el segundo caso, usar el peso como una tercera dimensión es más apropiado.

Table 7: Modificaciones respecto al algoritmo estándar

Paso	Descripción	¿Modificado?
1	Calcular distancias	No
2	Core distances	No
3	Mutual reachability	No
4	MST (Prim/Kruskal)	No
5	Extender MST	No
6	Dendrograma	Sí (validez por masa)
7	Simplificar	Sí (validez por masa)
8	Estabilidades	Sí (suma ponderada)
9	Extracción óptima	No (misma lógica)

10 Resumen del Algoritmo HDBSCAN con Pesos

11 Conclusiones

La extensión de HDBSCAN con pesos:

1. **Preserva la geometría:** Las distancias y el MST no cambian
2. **Modifica la masa:** El criterio de cluster válido usa $W(C)$ en lugar de $|C|$
3. **Pondera la estabilidad:** Puntos con mayor peso contribuyen más a S_w
4. **Puede cambiar el resultado:** Grupos con baja masa total pueden convertirse en ruido
5. **Es consistente:** Con pesos unitarios, se recupera el algoritmo estándar

En el ejemplo:

- El grupo C (peso total = 8) no alcanza el umbral $m_{\text{clSize}} = 15$
- El grupo A1 (peso total = 40) tiene la mayor estabilidad ponderada
- El resultado final tiene 3 clusters + ruido, vs. 4 clusters sin pesos